Introdução a Redes Convolucionais: Arquitetura U-Net

Por **Gerônimo G. Z. Lemos**
e-mail: geronimo.lemos@inpe.br

Orientadores: Haroldo F. de Campos Velho e Juliana A. Anochi

2025

Redes Neurais Convolucionais (CNNs)

- As Redes Neurais Convolucionais (CNNs) continuam sendo o estado da arte para tarefas de visão computacional;
- Propostas por LeCun et al. (1989) para reconhecimento de dígitos manuscritos;
- Responsáveis pela nova onda de desenvolvimento da inteligência artificial, especialmente após 2012.

Primeira CNN: LeNet

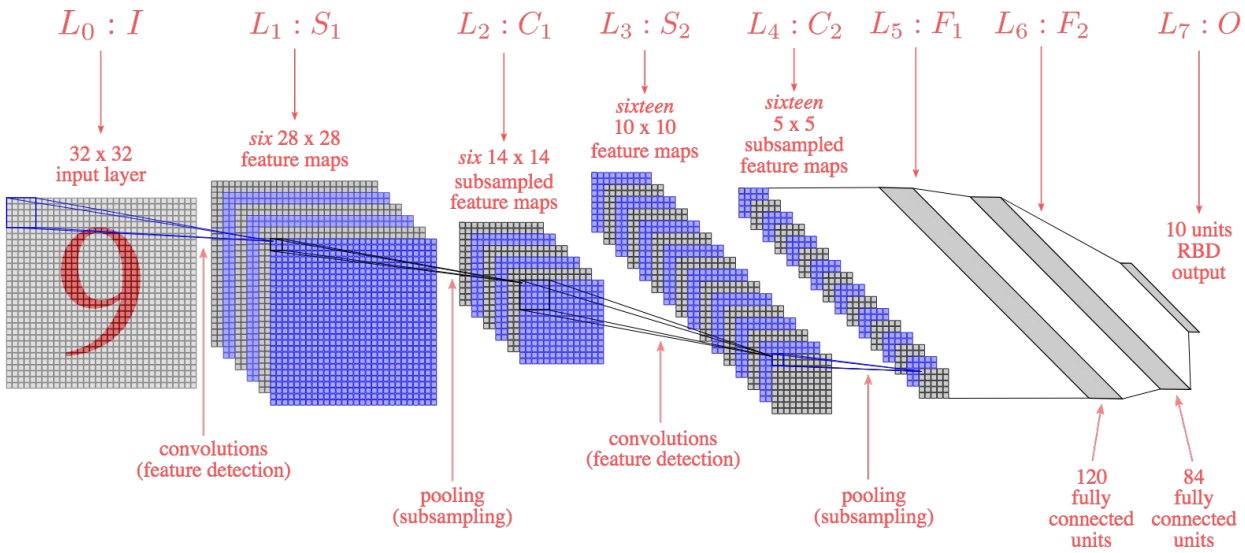

Exemplo retirado de:
https://medium.com/@abhishekjainindore24/semantic-vs-instance-vs-panoptic-segmentation-b1f5023da39f

Convolutional Layer

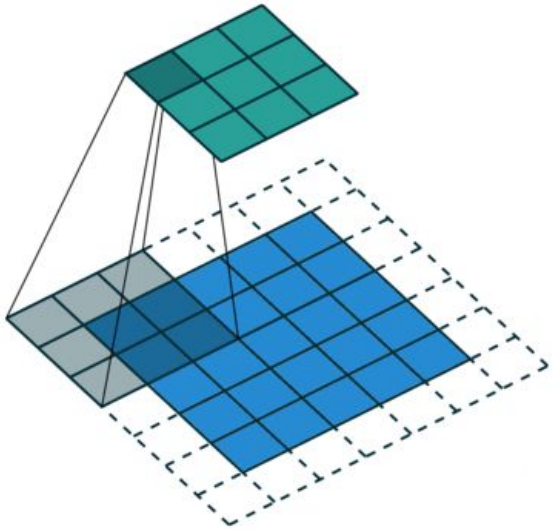

Exemplo retirado de:
https://commons.wikimedia.org/wiki/File:Convolution_arithmetic_-_Padding_strides.gif

First CNN: LeNet

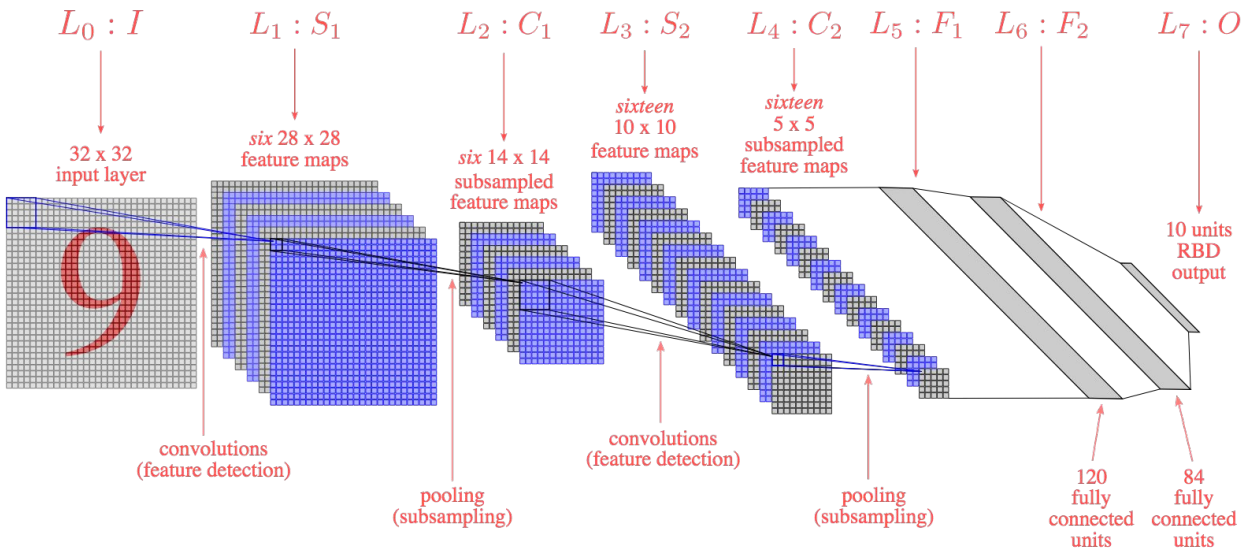

Exemplo retirado de:
https://medium.com/@abhishekjainindore24/semantic-vs-instance-vs-panoptic-segmentation-b1f5023da39f

Arquitetura U-Net

Arquitetura U-Net

- Uso de uma Rede Neural Convolucional; Arquitetura escolhida: U-Net;
- A arquitetura U-Net foi originalmente proposta para segmentação semântica;
- Foi necessário fazer uma modificação em sua camada de saída para adaptar a arquitetura ao problema estudado;
- 3 blocos principais: *Encoder*, *Bottleneck* e *Decoder*.

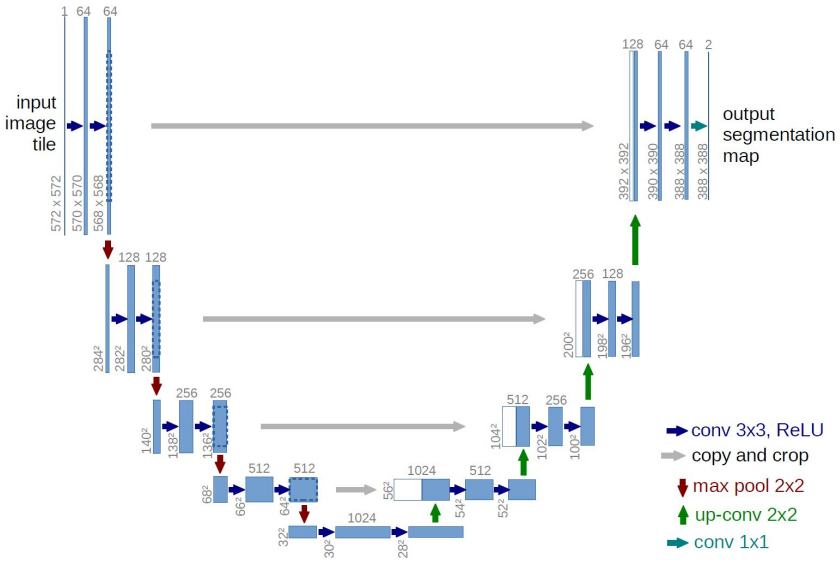

Fonte: RONNEBERGER, Olaf; FISCHER, Philipp; BROX, Thomas. U-net: Convolutional networks for biomedical image segmentation. In: **Medical image computing and computer-assisted intervention–MICCAI 2015: 18th international conference, Munich, Germany, October 5-9, 2015, proceedings, part III 18**. Springer International Publishing, 2015. p. 234-241.

U-Net: *Encoder*

- Bloco que segue os passos típicos do processamento CNN; Camadas de convolução duplas;
- Camadas de convolução duplas;
- Operações realizadas: convolução, funções de ativação não lineares e max-pooling;
- Extrator de características.

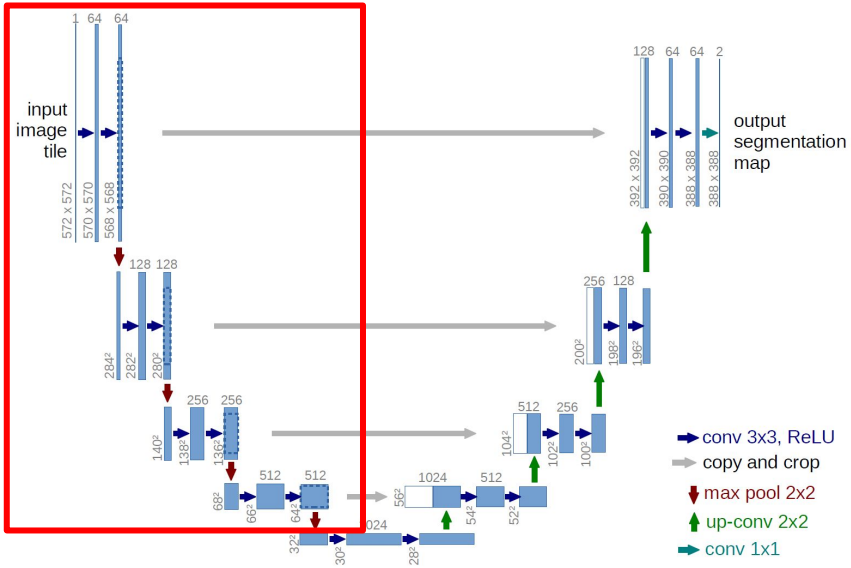

Fonte: RONNEBERGER, Olaf; FISCHER, Philipp; BROX, Thomas. U-net: Convolutional networks for biomedical image segmentation. In: **Medical image computing and computer-assisted intervention–MICCAI 2015: 18th international conference, Munich, Germany, October 5-9, 2015, proceedings, part III 18**. Springer International Publishing, 2015. p. 234-241.

U-Net: *Bottleneck*

- Camada mais profunda da arquitetura;
- Nesta camada, é gerada a representação do espaço latente dos dados de entrada;
- A partir desta representação, os dados são reconstruídos pelo Decodificador;
- Aplica as mesmas operações do bloco anterior, com exceção do max-pooling;

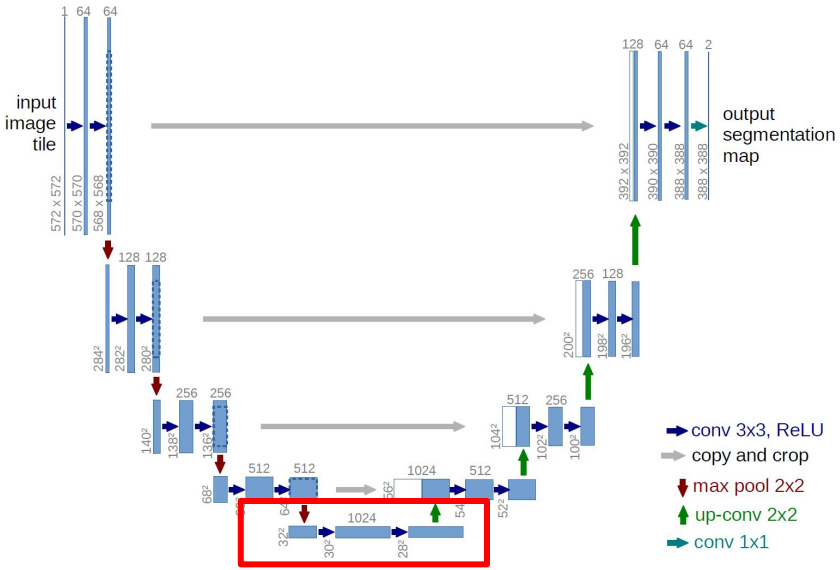

Fonte: RONNEBERGER, Olaf; FISCHER, Philipp; BROX, Thomas. U-net: Convolutional networks for biomedical image segmentation. In: **Medical image computing and computer-assisted intervention–MICCAI 2015: 18th international conference, Munich, Germany, October 5-9, 2015, proceedings, part III 18**. Springer International Publishing, 2015. p. 234-241.

U-Net: *Decoder*

- Bloco responsável por reconstruir a imagem de entrada;
- Para isso, aplica-se a função de convolução inversa, aplicada no Encoder;
- Ao final deste processo, aplica-se a função de ativação Softmax para gerar a máscara de segmentação.

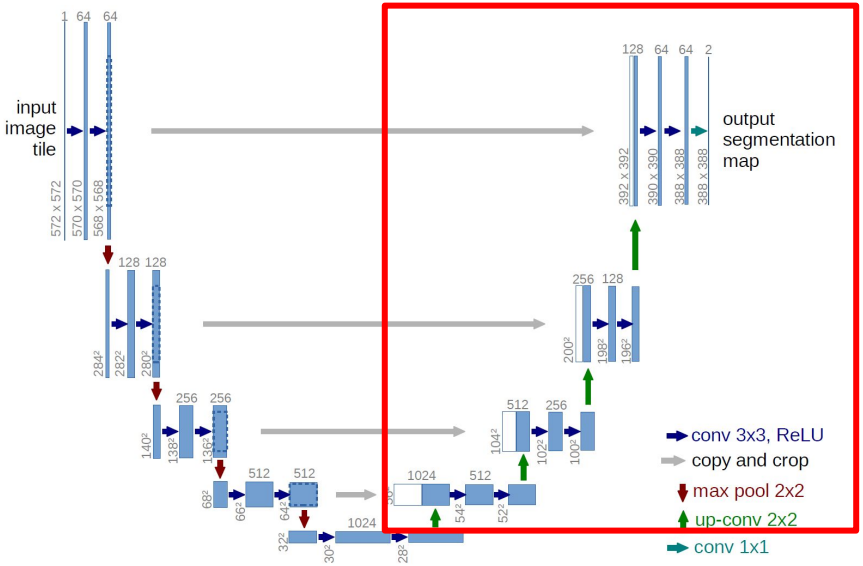

Fonte: RONNEBERGER, Olaf; FISCHER, Philipp; BROX, Thomas. U-net: Convolutional networks for biomedical image segmentation. In: **Medical image computing and computer-assisted intervention–MICCAI 2015: 18th international conference, Munich, Germany, October 5-9, 2015, proceedings, part III 18**. Springer International Publishing, 2015. p. 234-241.

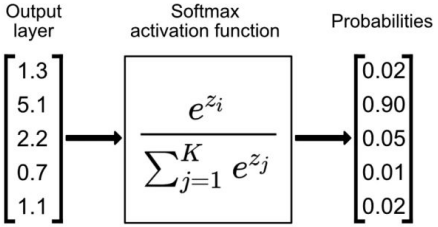

Onde:

zi: valor do pixel de entrada
K: total de pixels na imagem

Skip connections

- Operação entre os blocos Codificador e Decodificador;
- Concatena a saída das camadas de Convolução Dupla com as entradas das camadas Decodificador;
- Antes do Max-pooling;
- **Objetivo principal**: Preservar a informação espacial e restaurar a dimensão original dos dados.

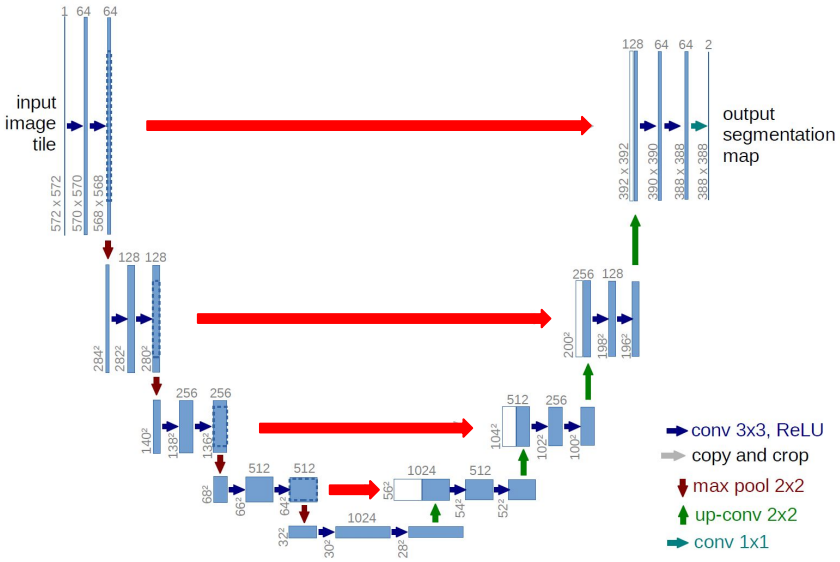

Fonte: RONNEBERGER, Olaf; FISCHER, Philipp; BROX, Thomas. U-net: Convolutional networks for biomedical image segmentation. In: **Medical image computing and computer-assisted intervention–MICCAI 2015: 18th international conference, Munich, Germany, October 5-9, 2015, proceedings, part III 18**. Springer International Publishing, 2015. p. 234-241.

Segmentação semântica usando U-Net

Exemplo retirado de:
https://keras.io/examples/vision/oxford_pets_image_segmentation/

U-Net para geração de análise

Fonte: O Autor

TensorFlow + Keras

TensorFlow + Keras

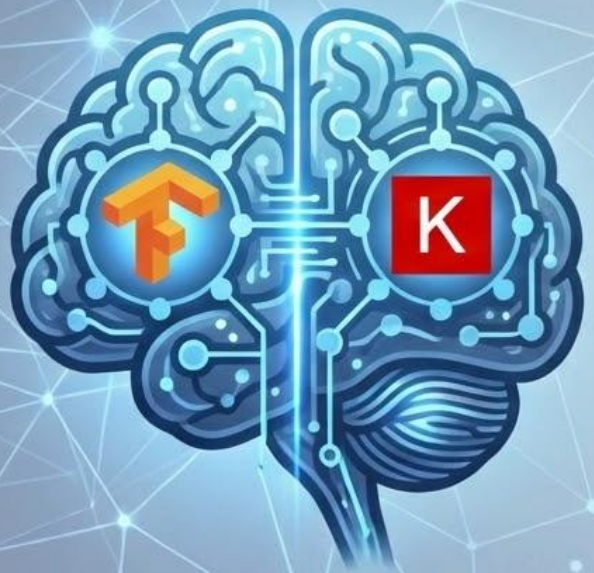

TensorFlow é uma biblioteca de código aberto para aprendizado de máquina aplicável a uma ampla variedade de tarefas.

Criada pelo Google em 2015 é a principal biblioteca para criação e treinamento de RNAs.

A API toda é escrita em Python mas é executada em C++ na CPU ou em CUDA na GPU.

TensorFlow + Keras

Fácil Construção & Experimentação Rápida

Keras facilita o treinamento de RNAs, com foco em permitir a experimentação rápida.

RNAs Pré-treinadas

Fornece uma ampla variedade de modelos prontos para várias tarefas.

Recursos e Exemplos

Dowload: https://keras.io/
Exemplos: https://keras.io/examples/

Keras: Algoritmos de Otimização

Keras possui diversos:/

SGD: Stochastic Gradient Descent

SGD com Momento: SGD com Momento usando a derivada (ou gradiente) do ponto atual

SGD com Momento Nesterov: SGD com Momento mas usa a derivada (ou o gradiente) parcial do ponto seguinte (Nesterov, 1983)

RMSprop: SGD com taxa de aprendizagem adaptativa (Hinton, Srivastava & Swersky, 2012) -- RMSProp

AdaGrad: SGD com taxa de aprendizagem adaptativa (Duchi, Hazan, & Yoram, 2011) -- AdaGrad

Adam: SGD com taxa de aprendizagem adaptativa e momento (Kingma, Diederick & Jimmy, 2014) --- ADAM

Os mais usados são o SGD e o Adam

TensorFlow + Keras

- **Funções Essenciais**
  - Funções de otimização (Ex: Gradiente descendente)
  - Funções de custo (Ex: MSE)
  - Funções de ativação (Ex: Relu)

Custo
MSE

Ativação
Relu

Design e Conceitos da Rede

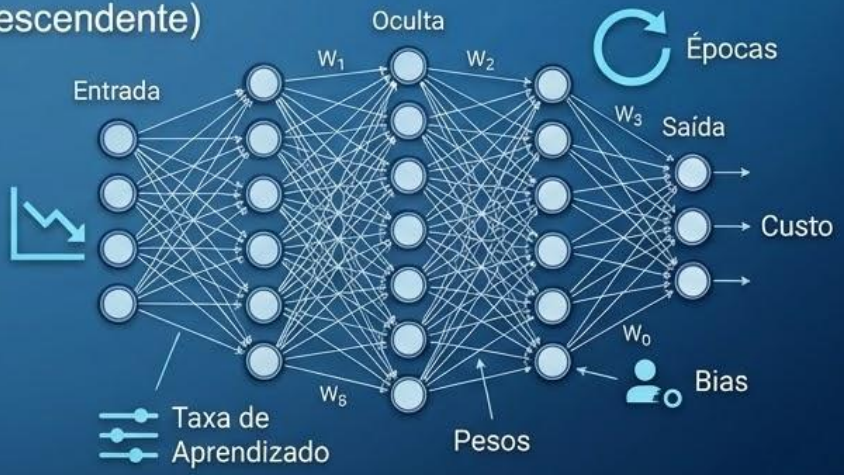

- Design da rede (camadas, neurônios, arquitetura) é essencial!
- Conceito de épocas, custo, taxa de aprendizado, pesos e bias.

Obrigado!

Introdução a Redes Convolucionais: Arquitetura U-Net

Por **Gerônimo G. Z. Lemos**
e-mail: geronimo.lemos@inpe.br

Orientadores: Haroldo F. de Campos Velho e Juliana A. Anochi

2025