Assimilação de dados por aprendizado de máquina

Haroldo F. de Campos Velho - INPE
Helaine C. M. Furtado - UFOPA
Juliana A. Anochi - INPE
Roberto P. Souto - LNCC
Marcelo Paiva - INPE
César Magno L. de Oliveira Júnior – USP
Geronimo Lemos - INPE

Inteligência Artificial

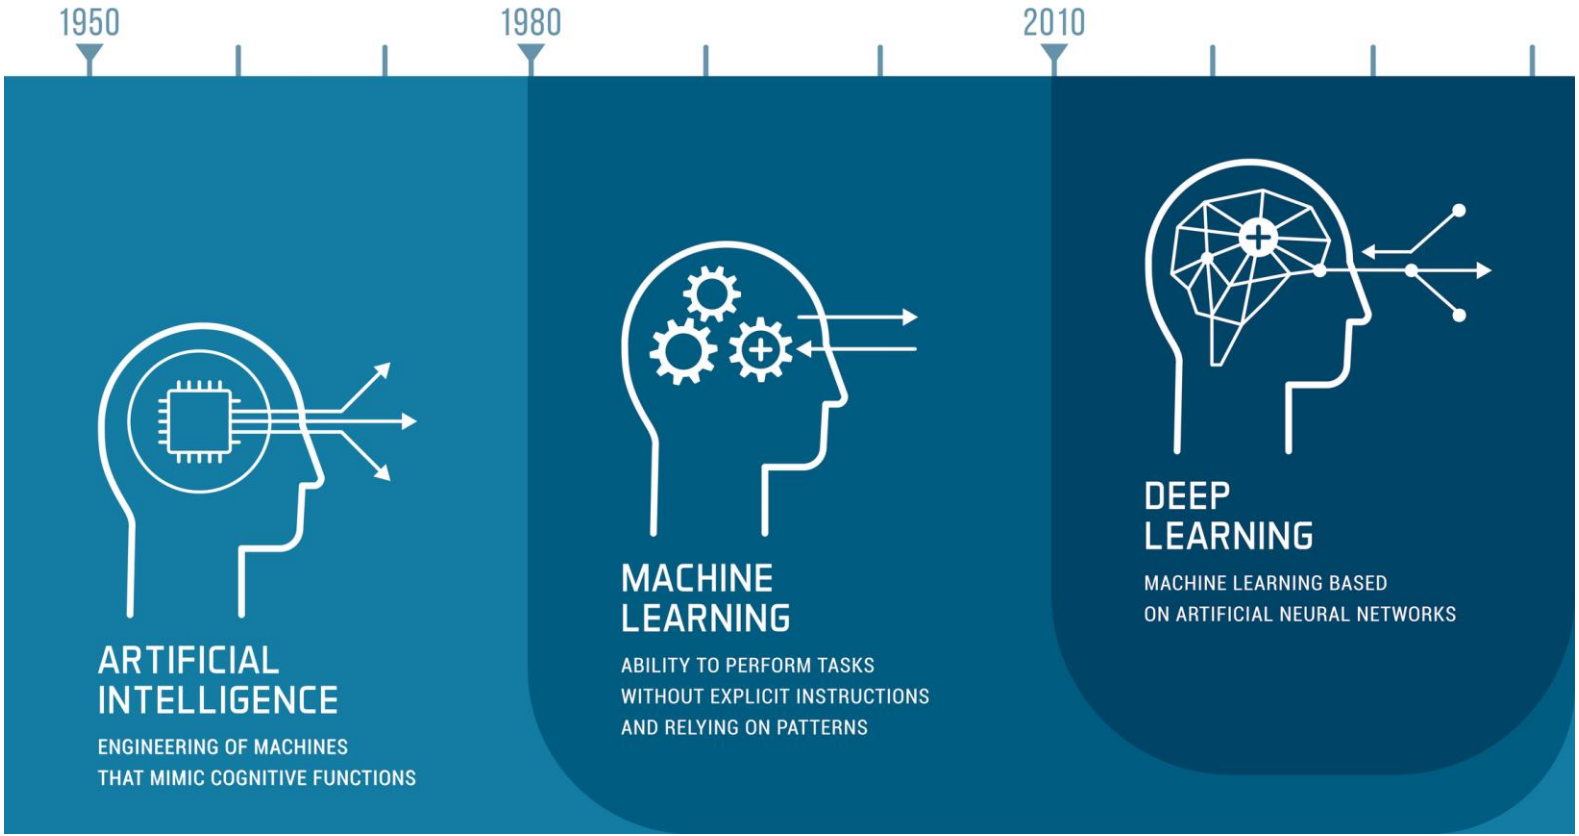

Inteligência Artificial

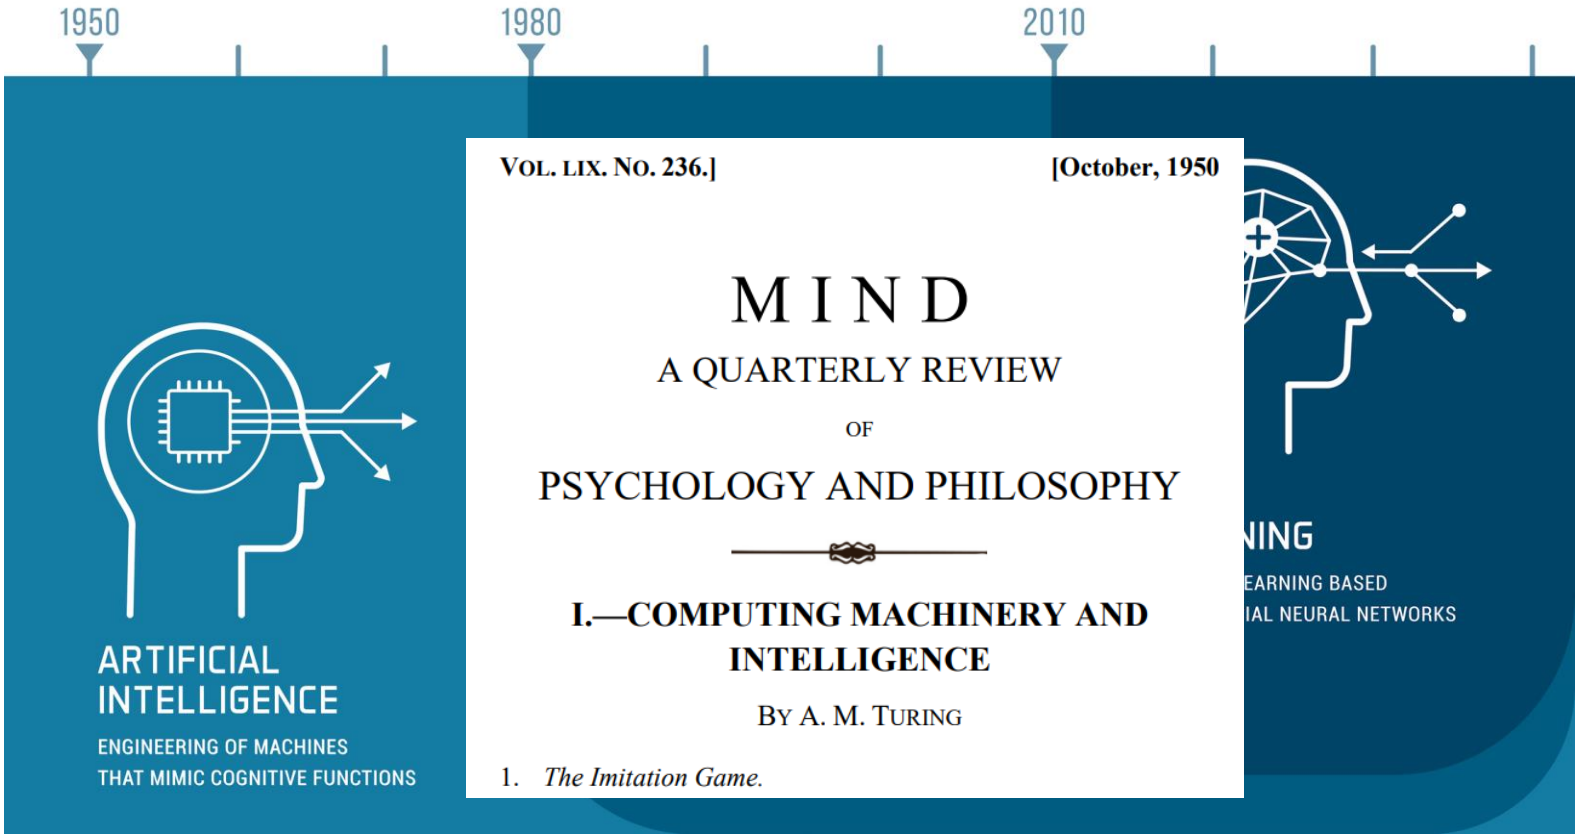

Teste de Turing 1950

1. **Configuração**
   - Um juiz humano faz perguntas a dois participantes. As respostas são trocadas via texto.

2. **Objetivo**
   - A máquina deve gerar respostas convincentes para enganar o juiz, fazendo-o acreditar que está conversando com um humano.

3. **Critério de aprovação**
   - Se a máquina conseguir convencer o juiz em uma proporção significativa, considera-se que ela passou no Teste de Turing.

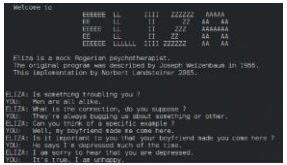

Chatbot 1966

ChatGPT 2022

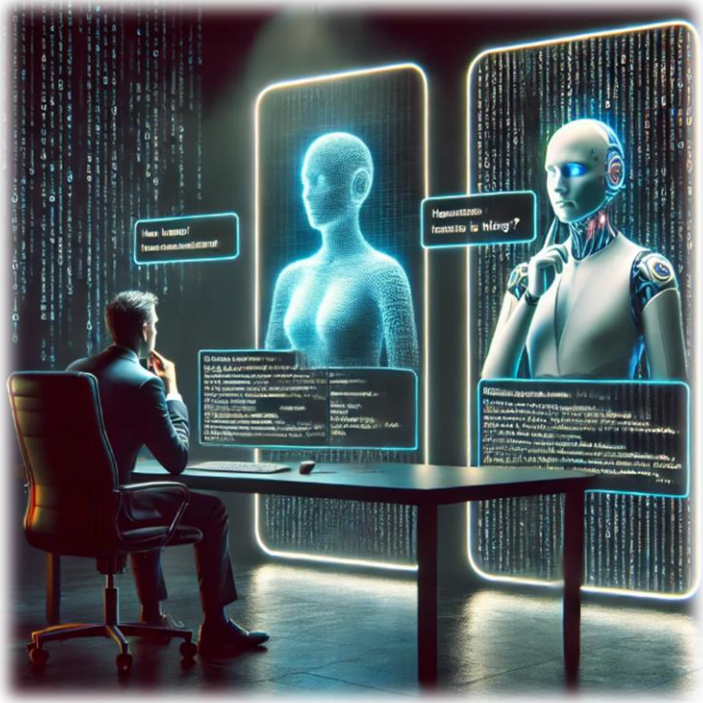

Fonte: ChatGPT

O que é uma rede neural artificial?

Reproduzir

→

Inteligência humana

- Aprendizado: aquisição de conhecimento a partir de amostras de treinamento, por meio do ajuste dos pesos sinápticos.
- Armazenamento: conhecimento aprendido é representado nas conexões (pesos) entre os neurônios artificiais
- Adaptação: ajusta-se a uma nova realidade (nova amostra de informação).

Aprendizado de máquina

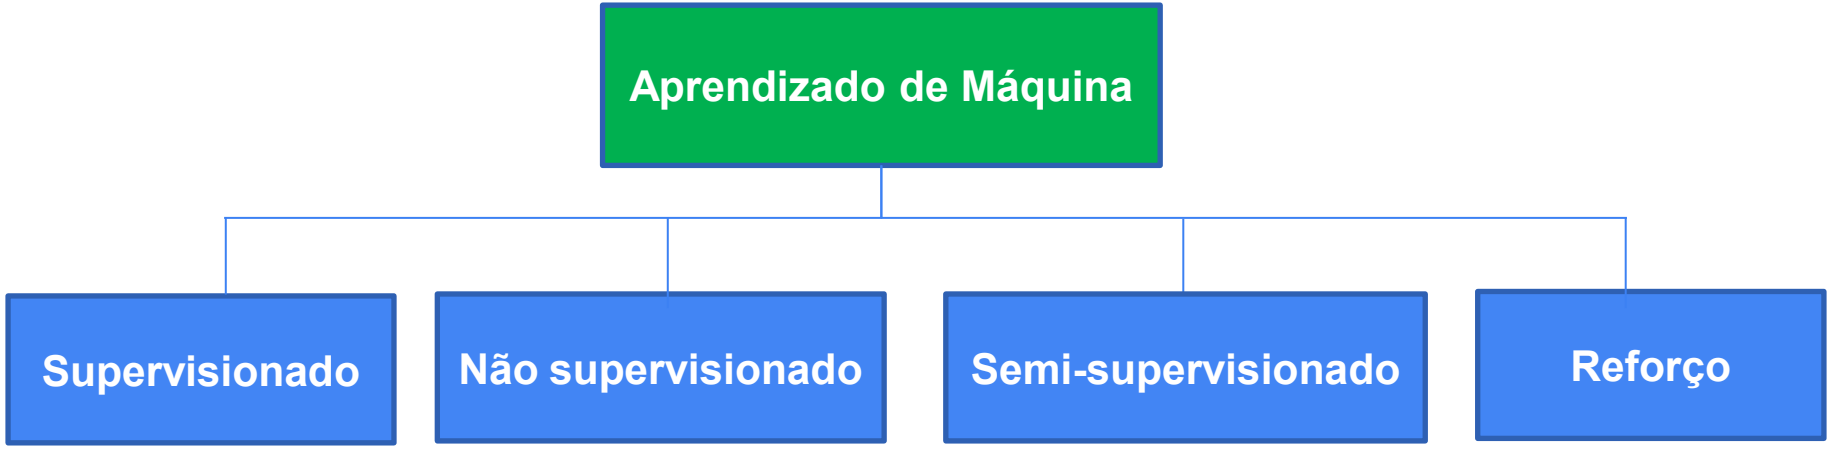

Perceptron de Múltiplas Camadas (MLP)

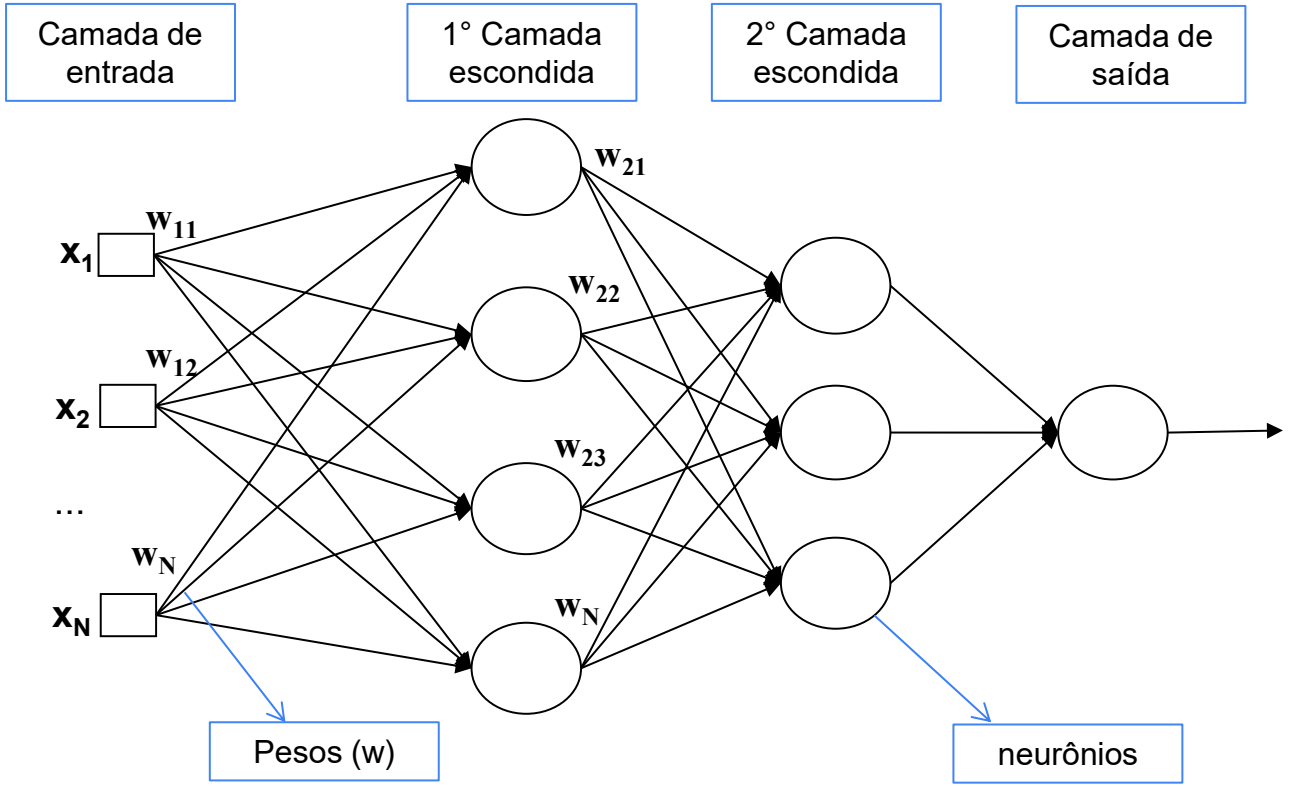

Problema: como definir os parâmetros ?

- Os **hiperparâmetros** são configurações ajustáveis que controlam o aprendizado do modelo, mas que não são aprendidas a partir dos dados.

  - **learning_rate** (taxa de aprendizado)
  - **n_layers** (número de camadas ocultas)
  - **n_neurons** (número de neurônios por camada)
  - **batch_size** (tamanho do batch)
  - **dropout_rate** (taxa de dropout)
  - **activation_function** (função de ativação, ex: relu, tanh)
  - **optimizer** (ex: adam, sgd)
  - **epochs** (número máximo de épocas)
  - **l2_reg** (regularização)

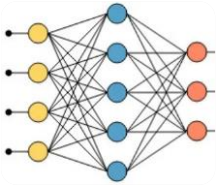

Métodos: busca de hiperparâmetros

Método	Estratégia de Busca	Estratégia de Treinamento	Exemplos
Grid Search (Busca exaustiva)	Grade fixa e exaustiva	Treina o modelo para todas as combinações	`GridSearchCV` (Scikit-learn)
Random Search (Busca aleatória)	Amostragem aleatória	Treina para combinações amostradas aleatoriamente	`RandomizedSearchCV` (Scikit-learn)
Bayesian Optimization	Modelo probabilístico + função de aquisição	Treinamento iterativo guiado por modelo probabilístico substituto	Optuna
Metaheurísticas	Busca populacional estocástica	Treinamento iterativo de população de soluções	Algoritmo Genético, PSO, MPCA

Métodos: busca de hiperparâmetros

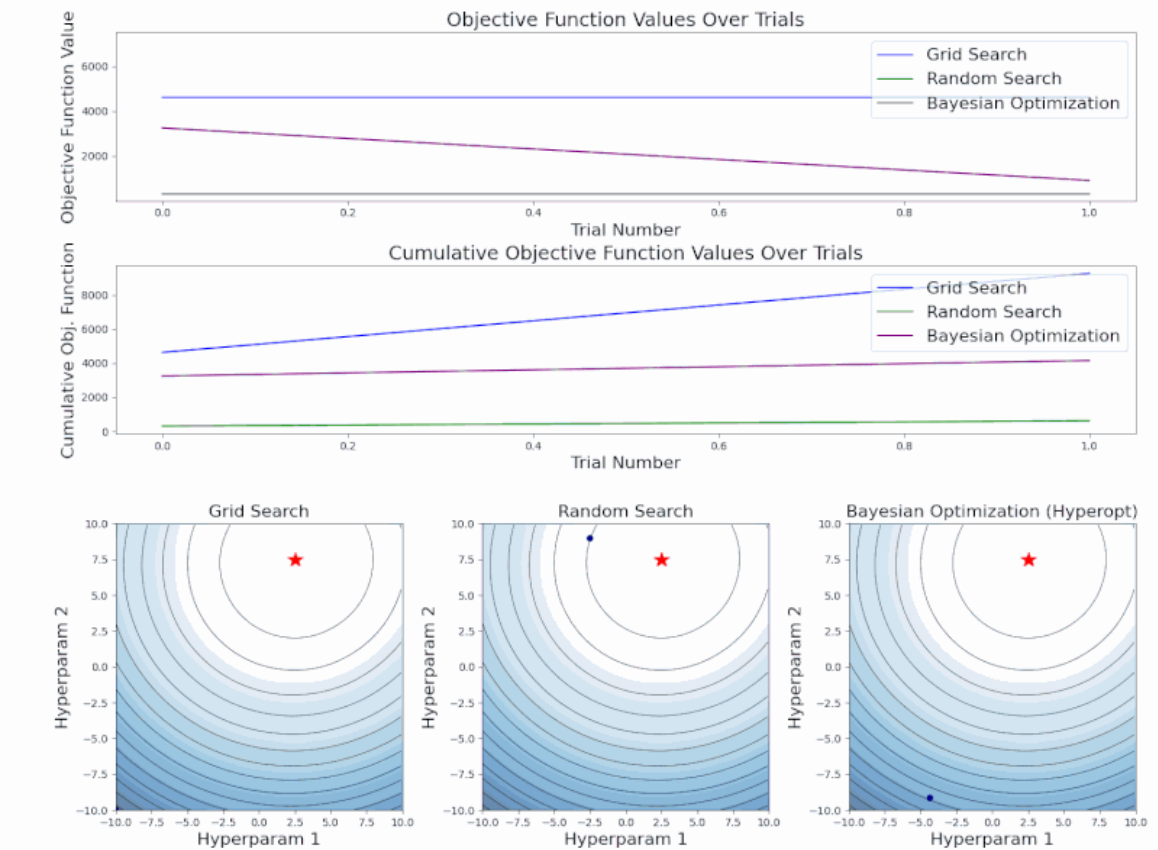

Fonte: Timur Bikmukhametov
https://www.linkedin.com/feed/update/urn:li:activity:7349787267915296769/?utm_source=share&utm_medium=member_android&rcm=ACoAADRPWWIB4pUAzd4Vx1iLqD5Bgz0UPfX-BCQ

Solução: Metaheurística

TRATAR COMO UM PROBLEMA DE OTIMIZAÇÃO

↓

ENCONTRAR O MELHOR CONJUNTO DE PARÂMETROS QUE OTIMIZEM UMA FUNÇÃO OBJETIVO

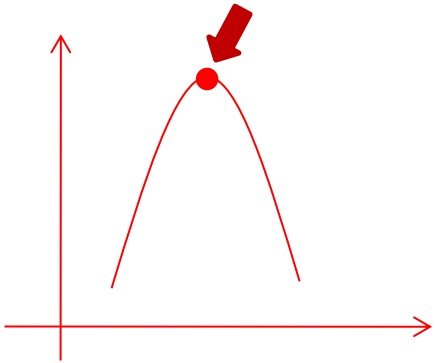

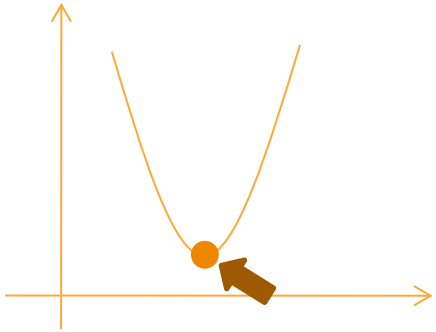

Algoritmo de Colisão de Múltiplas Partículas (MPCA)

Disponível para download:
www.epacis.net/jcis/PDF_JCIS/JCIS11-art.01.pdf

Pan-American Association of Computational Interdisciplinary Sciences

Journal of Computational Interdisciplinary Sciences (2008) 1(1): 3-10
© 2008 Pan-American Association of Computational Interdisciplinary Sciences
ISSN 1983-8409
http://epacis.org

A new multi-particle collision algorithm for optimization in a high performance environment

Eduardo Fávero Pacheco da Luz, José Carlos Becceneri and Haroldo Fraga de Campos Velho

Manuscript received on July 31, 2008 / accepted on October 5, 2008

Algoritmo de Colisão de Múltiplas Partículas (MPCA)

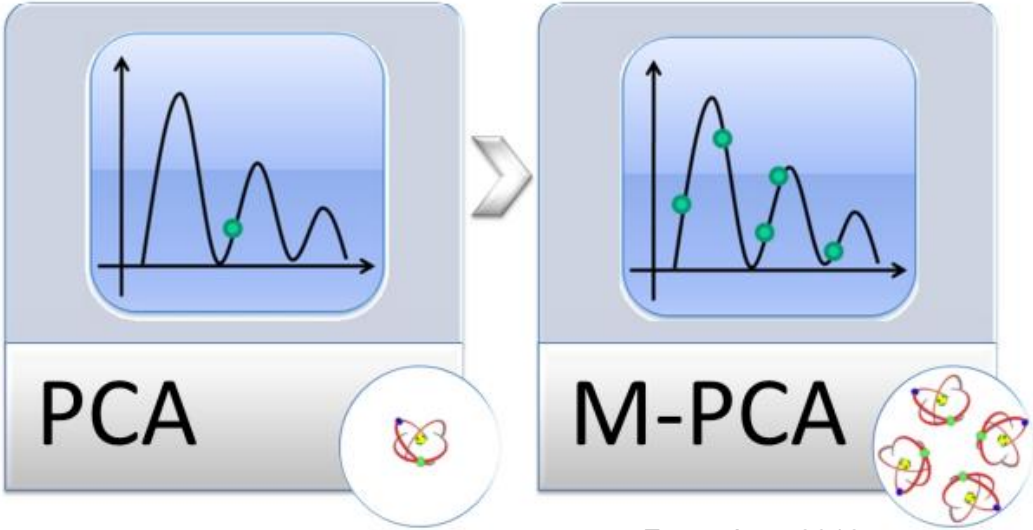

Fonte: Luz, 2012

- O PCA explora o espaço de busca com uma única partícula.
- O MPCA, simula a adoção de *n*-partículas na exploração colaborativa do espaço de buscas, apresentando ganho de performance.

Algoritmo de Colisão de Múltiplas Partículas (MPCA)

```
Gera uma solução inicial: Old_Config
Best_Fitness = Fitness(Old_Config)
Para n=0 até # de iterações
    Para p=0 até  # de partículas
            Perturbation()
            Se Fitness(New_Config) > Fitness(Old_Config)
                Se Fitness(New_Config) > Best_Fitness
                    Best_Fitness := Fitness(New_Config)
                Fim-se
                    Old_Config = New_Config
                    Exploration()
                Senão
                    Scattering()
            Fim-se
    Fim-para
Fim-para
```

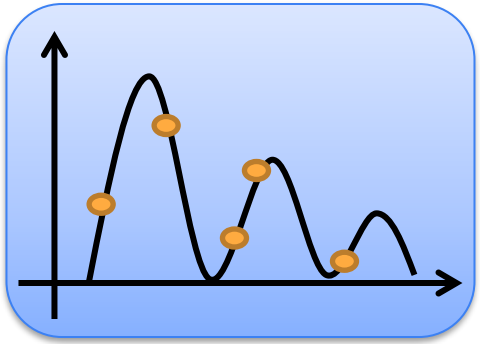

Fonte: Luz, 2012

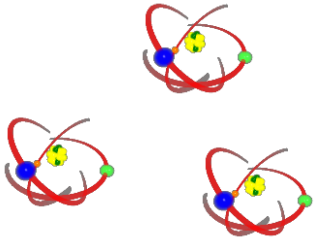

Algoritmo de Colisão de Múltiplas Partículas (MPCA)

Parâmetro	Intervalo de Valores
Número de camadas ocultas	[1, 2]
Neurônios por camada	[1, 100]
Taxa de aprendizado	[0.01, 0.9]
Momentum	[0.01, 0.9]
Função de ativação	Tangente | Logística | Gaussiana

$$F_{obj} = penalty * \frac{\left[\rho_1 * E_{trein} + \rho_2 * E_{gen}\right]}{\rho_1 + \rho_2}$$

$$penalty = \underbrace{\left(c_1 * \left(e^{\#\,neuron}\right)^2\right)}_{\text{complexity factor-1}} \times \underbrace{\left(c_2 * (\#\,epoch)\right)}_{\text{complexity factor-2}} + 1$$

$$MSE = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$$

Aplicações usando RNA&MPCA

- **Aplicações RNA&MPCA**
  - Assimilação de dados (Furtado, 2012)
  - Previsão climática (Anochi, 2021)
  - Estimação de temperatura (perfil atmosférico) (Sambati, 2012)
  - Navegação autônoma de Vant (Braga, 2018)
  - Modelo Fluidity (Paiva, 2025)

- RNA&MPCA está disponível para download:
  - https://github.com/scsr-inpe/mpca-ann
  - https://github.com/sabrinabms/RNA-MPCA

- Contato:
  - juliana.anochi@inpe.br
  - marcelo.paiva@inpe.br
  - haroldo.camposvelho@inpe.br

Assimilação de dados por aprendizado de máquina

Haroldo F. de Campos Velho - INPE
Helaine C. M. Furtado - UFOPA
Juliana A. Anochi - INPE
Roberto P. Souto - LNCC
Marcelo Paiva - INPE
César Magno L. de Oliveira Júnior – USP
Geronimo Lemos - INPE